Анализ IT-вакансий: вариант 10 «Аналитик»

Домашнее задание по объектному хранилищу и распределённым вычислениям. Датасет: it_vacancies_2024.csv; источник — файл, предоставленный студентом. Дата подготовки: 18 октября 2026 г.

1. Инфраструктура и воспроизводимость

Локальный RustFS запущен в Docker на портах 9000 (S3 API) и 9001 (консоль). Бакет: hh-lake. Проверка GET /health вернула HTTP 200. Использованы официальный образ rustfs/rustfs:latest и постоянный Docker volume. Ключи доступа хранятся вне сдаваемого проекта.

Объект в hh-lake	Размер, байт
analyst_variant10.csv	5 431 193
it_vacancies_2024.csv	847 619 384
it_vacancies_2024_projection.csv	41 294 053
results/analyst/duckdb_k1.csv	204 250
results/analyst/duckdb_k2.csv	6 361 433
results/analyst/duckdb_k3.csv	65 493 555
results/analyst/mapreduce_k1.csv	204 250
results/analyst/mapreduce_k2.csv	6 361 433
results/analyst/mapreduce_k3.csv	65 493 555

Снимок фактического вывода команд:

```
docker ps: rustfs-analyst-hw Up 47 minutes
curl http://127.0.0.1:9000/health: HTTP 200
S3: hh-lake/it_vacancies_2024.csv  847619384 bytes
S3: hh-lake/analyst_variant10.csv  5431193 bytes
S3: hh-lake/it_vacancies_2024_projection.csv  41294053 bytes
```

Файл analyst_variant10.csv содержит 30 112 строк своего варианта. Проекция содержит все 229 388 строк исходного CSV и семь необходимых колонок. Оба метода читают один и тот же объект проекции из S3 и самостоятельно фильтруют роль. Условие: точное равенство role = «Аналитик».

2. Правила расчёта

Навыки разделяются по «;», приводятся к нижнему регистру, очищаются от пробелов и дедублируются в пределах вакансии. Каждая комбинация учитывается один раз на вакансию; порядок навыков в паре и тройке не важен. MapReduce читает поток S3 чанками по 1 000 строк: mapper формирует три локальных счётчика, reducer складывает их. DuckDB независимо применяет фильтр role в SQL, разворачивает список навыков и выполняет соединения для k=1,2,3.

```
SELECT vacancy_id, key_skills
FROM read_csv('s3://hh-lake/it_vacancies_2024_projection.csv',
              all_varchar=true)
WHERE role = 'Аналитик';
-- Пара: a.vacancy_id=b.vacancy_id AND a.pos<b.pos
-- Тройка: a.pos<b.pos AND b.pos<c.pos
```

3. Частоты и полная верификация

Отобрано 30 112 вакансий; навыки заполнены у 17 932.

Размер набора	Уникальных сочетаний	Всего вхождений	Расхождений
1	5 663	120 104	0
2	96 052	506 354	0
3	651 371	1 877 380	0

Скрипт verify.py сравнил полные словари «комбинация → частота» для всех трёх размеров. Во всех случаях различий нет. CSV результатов MapReduce и DuckDB для k=1,2,3 сохранены в hh-lake/results/analyst/.

Рост общего числа вхождений: пары / одиночные навыки = 4,22; тройки / пары = 3,71. В вакансии с n навыками создаётся C(n,1), C(n,2), C(n,3) сочетаний; поэтому число сочетаний растёт быстрее числа вакансий.

Самые частые сочетания, k=1

Навыки	Частота
аналитическое мышление	4971
sql	4113
анализ данных	3162
работа с большим объемом информации	2987
ms excel	2855

Самые частые сочетания, k=2

Навыки	Частота
анализ данных + аналитическое мышление	1617
аналитическое мышление + работа с большим объемом информации	1569
аналитика + аналитическое мышление	1225
анализ данных + работа с большим объемом информации	1165
анализ данных + аналитика	1058

Самые частые сочетания, k=3

Навыки	Частота
анализ данных + аналитическое мышление + работа с большим объемом информации	722
анализ данных + аналитика + аналитическое мышление	619
bpmn + sql + uml	487
аналитика + аналитическое мышление + работа с большим объемом информации	470
анализ данных + аналитическое мышление + сбор и анализ информации	466

4. Сравнение времени и памяти

Каждый метод запущен трижды в отдельном процессе на одном объекте S3. Время включает чтение и подсчёт, но не запись результирующих CSV. Пик RSS процесса измерялся опросом каждые 10 мс. Замеры относятся к данной локальной машине и зависят от кэша ОС и Docker.

Метод	Попытка 1	Попытка 2	Попытка 3	Медиана
MapReduce	1.784 с / 152.3 МБ	1.802 с / 153.2 МБ	1.793 с / 151.9 МБ	1.793 с / 152.3 МБ
DuckDB	1.377 с / 698.3 МБ	1.291 с / 813.7 МБ	1.851 с / 604.1 МБ	1.377 с / 698.3 МБ

На медианах DuckDB быстрее на 23.2%, но использует примерно 4.6 раза больше памяти. Разброс времени DuckDB выше (1,291–1,851 с). Для этого набора данных потоковый MapReduce экономнее по памяти, а SQL удобен для независимой проверки и оказался быстрее по медиане.

Бонус: оптимизация чтения из S3

MapReduce: исходный CSV 847,6 МБ → проекция 41,3 МБ с теми же строками и семью нужными колонками. Подготовка проекции выполнена один раз до замеров.

Входной объект	Попытка 1	Попытка 2	Попытка 3	Медиана
Исходный CSV	7.109 с / 158.4 МБ	7.072 с / 166.3 МБ	7.264 с / 163.5 МБ	7.109 с / 163.5 МБ
Проекция	1.730 с / 154.1 МБ	1.746 с / 153.1 МБ	1.730 с / 152.2 МБ	1.730 с / 153.1 МБ

Медианы: время уменьшилось на 75.7%, пик памяти — на 6.3%. Три итоговых CSV до и после совпали по SHA-256.

5. Три региона: объём и зарплата

Регион	Вакансий	С зарплатой RUR	Медиана, ₽
Москва	13280	3542	130 000
Санкт-Петербург	3005	1111	103 900
Екатеринбург	1223	568	75 000

Зарплата: только RUR; при двух границах берётся их среднее, при одной — указанная граница. Вакансии без зарплаты не входят в медиану. Это оценка предложений, а не фактической оплаты.

6. Три региона: востребованность навыков

Регион	Набор	Лидер по частоте	Частота
Москва	Навык	sql	2263
Москва	Пара	python + sql	695
Москва	Тройка	анализ данных + аналитика + аналитическое мышление	255
Санкт-Петербург	Навык	аналитическое мышление	511
Санкт-Петербург	Пара	анализ данных + аналитическое мышление	149
Санкт-Петербург	Тройка	bpmn + sql + uml	63
Екатеринбург	Навык	аналитическое мышление	228
Екатеринбург	Пара	анализ данных + аналитическое мышление	70
Екатеринбург	Тройка	анализ данных + аналитическое мышление + сбор и анализ информации	35

В Москве медиана выше Санкт-Петербурга на 26 100 ₽ и Екатеринбурга на 55 000 ₽. Лидер пар в Москве — Python + SQL (695), в двух других регионах — анализ данных + аналитическое мышление. Это различие спроса, не причинный эффект.

7. Связь сочетаний навыков с медианной зарплатой

Для пары базой служит более частый из её одиночных навыков; для тройки — наиболее частая из её пар. Частота базы определяется по всем вакансиям, а медианы — по вакансиям с рублёвой зарплатой. Требование устойчивости: минимум 30 оплачиваемых вакансий для сочетания и базы. Изучено 1 184 пары и 1 602 тройки, прошедшие порог.

Повышение: пары

Сочетание	n	Медиана, ₽	База	База, ₽	Δ, ₽
soap + sql	52	227 500	sql	110 000	+117 500
rest + sql	77	225 000	sql	110 000	+115 000

Понижение: пары

Сочетание	n	Медиана, ₽	База	База, ₽	Δ, ₽
bpmn + crm	31	80 000	bpmn	150 000	-70 000
crm + разработка технических заданий	40	75 000	разработка технических заданий	140 000	-65 000

Повышение: тройки

Сочетание	n	Медиана, ₽	База	База, ₽	Δ, ₽
erp-системы на базе 1с + аналитика + сбор и анализ информации	34	190 000	аналитика + сбор и анализ информации	80 000	+110 000
erp-системы на базе 1с + аналитическое мышление + сбор и анализ информации	38	180 000	аналитическое мышление + сбор и анализ информации	72 500	+107 500

Понижение: тройки

Сочетание	n	Медиана, ₽	База	База, ₽	Δ, ₽
оптимизация бизнес-процессов + постановка задач разработчикам + системный анализ	38	80 000	постановка задач разработчикам + системный анализ	150 000	-70 000
бизнес-анализ + оптимизация бизнес-процессов + постановка задач разработчикам	33	80 000	бизнес-анализ + постановка задач разработчикам	150 000	-70 000

Пример роста: SOAP + SQL — 227 500 ₽ против 110 000 ₽ у SQL (+117 500 ₽; n=52). Снижение: BPMN + CRM — 80 000 ₽ против 150 000 ₽ у BPMN (-70 000 ₽; n=31). В группе BPMN + CRM только 3/31 вакансий требуют 3–6 лет опыта против 155/482 у BPMN; часты вакансии внедрения CRM. Это вероятное различие состава вакансий, а не причинный эффект навыка.

8. Проверка устойчивости и ограничения

Для теста отказа mapper искусственно вызван сбой на 10-м чанке. Программа повторила обработку именно этого чанка один раз, после чего полный словарь частот снова совпал с DuckDB. Данные хранилища при повторе не изменялись.

Навыки в CSV записаны свободным текстом: варианты написания могут обозначать одно и то же. Зарплата раскрыта не для всех вакансий, а односторонние границы дают лишь приближение. Следующий шаг для более строгого вывода — стратифицировать вакансии по опыту, региону и типу работодателя.

Приложение. Снимки локальной консоли RustFS

Источник снимков — встроенная веб-консоль локального RustFS по адресу http://127.0.0.1:9001. В ней видны бакет hh-lake, объект своего варианта и шесть файлов частот для двух методов.



